3. 실험설계

본 실험은 공통 GenAI 가 펀드별 조건에 맞는 배분 차이를 유지하는지, 기관별 근거의 제공 단계에 따라 차이의 정합성과 기대수익 손실이 달라지는지 비교한다.

3.1 자료와 배분 과제

네 펀드(FCNTX, VPMCX, DODGX, TRBCX)의 2025 년 말 보유자료를 사용하고, 공개자료의 마감은 2026 년 3 월 말로 정하였다. 분류 가능한 주식만 Fama–French 12 개 산업(FF12)에 연결해 합계가 1 이 되도록 정규화한 비중을 h 로 정의하였다. 과제는 월간 사후 기대수익의 극대화이며, 목표비중은 비음수, 합계 1, 기존 보유비중의 분산 이하라는 세 조건을 충족해야 한다.

사전 기대수익과 위험은 2016~2025 년 French 산업별 월간 수익률[1]의 평균과 Ledoit–Wolf 수축 공분산[2]으로 추정하였다. 여기에 공통·펀드별 합성 전망을 결합하였다. 공통 전망과 해당 펀드의 전체 추가 전망을 사용해 동일한 제약하에서 계산한 최적 배분을 평가 기준으로 삼되 모델에는 제공하지 않았다. R0 의 공통 전망만을 사용한 기준도 보조적으로 계산하였다.

3.2 비교 조건

전망 정밀도 두 수준(r=0.5, 2)에서 결과 확인 전에 선정한 상황 각 다섯 개에 네 펀드와 네 자료 조건을 적용하여 총 160 개 업무 흐름을 실행하였다(조건별 1 회 반복). 각 흐름은 계획, 배분안 작성, 점검·수정으로 구성하였다. R1~R3 에는 BM25 로 검색한 상위 네 문서 조각으로 이루어진 동일한 근거 패킷을 제공했으며, 산업별 추가 전망 열두 항목이 모두 포함되었음을 확인하였다.

표 1. 단계별 근거 제공 조건

조건	계획	배분안 작성	점검·수정
R0	공통 정보	공통 정보	공통 정보
R1	추가 근거 제공	근거 유지	근거 유지
R2	공통 정보	추가 근거 제공	근거 유지
R3	공통 정보	공통 정보	추가 근거 제공

공통 정보와 이전 대화는 모든 조건에서 유지하고, 점검 단계에는 외부 코드의 제약 검사 결과를 전달하였다. 사후 기대수익 계산·제약 검사 도구의 사용은 선택 사항이며, 도구의 정보 범위는 해당 단계까지 제공된 자료로 제한하였다. 단계별 추가 왕복은 최대 두 번으로 제한하였다.

조건 간에는 근거의 최초 제공 시점뿐 아니라 활용 가능한 단계 수와 대화 이력도 함께 달라진다. 따라서 결과는 합성 전망과 단일 반복을 사용한 탐색적 비교로 해석하며, 순수한 시점 효과나 실제 운용자의 판단·실현수익률을 직접 보여주는 결과로 해석하지 않는다.

4. 실험과정과 평가방법

4.1 준비, 실행과 중단·재개

실험에 앞서 각 펀드의 현재 자산 보유상태와 위험척도를 확정하고, 상황별 투자 전망, 검색 자료 묶음, 기준배분을 준비하였다. 검색 자료는 키워드 기반의 문서 검색 방식인 BM25 를 이용해 관련도가 높은 네 개의 문서 조각을 선택하였다. 준비된 자료를 바탕으로 정해진 순서에 따라 각 실험 조건의 세 단계를 실행하였으며, 모델의 원래 응답과 비중 처리 결과를 동일한 실행 식별자 아래 저장하여 서로 대조할 수 있도록 하였다.

모든 조건에는 Qwen3-1.7B 의 Q4_K_M 양자화 모델을 사용하였다. 모델 선정은 실험에 사용할 로컬 컴퓨터의 메모리 용량과 반복 실험에 필요한 실행시간을 우선 고려하여 이루어졌다. 양자화는 모델 내부 수치의 정밀도를 낮추어 메모리 사용량을 줄이는 방식이다. 실행에는 Ollama 0.35.1 을 사용하였으며, Intel Arc 140V 에서 Vulkan 을 통해 모델을 구동하였다. 개발 과정에서는 해당 환경에서 입력 자료와 대화 이력을 처리할 수 있는지, 구조화된 출력과 도구 연결이 작동하는지, 실행시간과 메모리 사용량이 실험 수행에 적합한지를 점검하였다. 이는 정해진 장비에서 실험을 수행할 수 있는지에 대한 운영 점검이었다.

본 실험에서 모델이 맡은 역할은 제공된 투자 전망과 보유상태를 해석하고, 이를 바탕으로 계획과 목표 투자비중 및 변경량을 제시하는 것이었다. 검색, 사후분포와 기준배분 계산, 비중 검사·정규화 및 평가 지표 집계는 코드가 수행하였다. 따라서 모델에 요구된 능력은 대조군으로 사용하는 최적배분 생성이 아닌, 주어진 자료와 지시를 이해하고 이를 배분안으로 연결하는 능력이었다.

모델의 일반적인 과제 수행 능력에 관한 참고 근거로, Qwen 공식 기술보고서는 Qwen3-1.7B 의 non-thinking 모드에 대해 지시 준수 평가인 IFEval 에서 68.2, 수학 문제 평가인 MATH-500 에서 73.0 의 점수를 보고하였다. 다만 이러한 공개 평가 결과는 본 연구에서 사용한 양자화 모델과 생성 설정의 금융 판단 능력을 직접 검증한 결과는 아니다. 따라서 이를 기관투자자 수준의 투자 판단 능력이 입증되었다는 근거로 해석하지 않으며, 본 연구에서 요구한 구체적인 과제의 수행 수준은 실험 결과와 구분하여 살펴볼 필요가 있다.

답변 생성 설정은 모든 조건에서 temperature 0, seed 1001, thinking 비활성화로 동일하게 유지하였다. temperature 는 다음에 출력할 내용을 선택할 때 적용되는 무작위성을 조절하며, seed 는 난수 생성의 초기값이다. thinking 비활성화는 별도의 추론 모드를 사용하지 않는 설정을 뜻한다. 이 설정들은 조건 간 비교에서 생성 설정이 달라지는 것을 막기 위해 고정하였으며, 금융 판단 성능이 가장 높은 조합으로 검증된 것은 아니다. 또한 동일한 seed 를 사용하더라도 장비나 실행환경이 달라지면 완전히 같은 응답이 생성된다고 보장할 수 없음을 명시한다.

문맥 한도는 32,768 토큰, 각 단계의 출력 한도는 4,096 토큰으로 설정하였다. 토큰은 모델이 텍스트를 나누어 처리하는 단위이며, 문맥 한도는 한 번의 요청에서 처리할 수 있는 전체 텍스트 길이의 제한을 뜻한다. 모델이 제시한 비중과 코드의 검사·정규화를 거친 비중은 구분하여 저장하였다. 이는 코드의 사후 처리를 거친 결과와 모델이 처음부터 제시한 답변을 구별하기 위한 것이다. 본 연구의 결과는 해당 소형 양자화 모델과 고정된 설정에서 관찰한 탐색적 비교로 해석한다. 다른 모델이나 설정, 실제 기관투자자의 의사결정으로 결과를 일반화하는 데에는 한계가 있다.

본실험 응답을 생성하기 전에는 비교 기준을 계산하는 독립 수치 솔버의 수렴 문제를 수정하였다. 수치 솔버는 주어진 목적과 제약조건에 맞는 배분을 계산하는 프로그램이다. 수정 과정에서는 목적함수의 내부 수치 규모를 조정하고, 위험제약이 해를 제한하지 않는 경우에는 검증된 꼭짓점 해를 처리하도록 하였다. 이때 평가하려는 목적함수와 원래의 제약조건 및 허용오차는 유지하였다.

실행 중 재부팅이 발생한 경우에는 이미 저장된 완료 응답을 재사용하고, 응답이 저장되지 않은 요청만 동일한 입력으로 다시 실행하였다. 잘못된 답변을 원하는 결과가 나올 때까지 반복 생성하는 방식은 사용하지 않았다. 이러한 재개 규칙을 통해 중단 이전에 확보한 응답을 유지하고, 답변의 내용에 따라 재실행 여부가 달라지지 않도록 하였다.

실험은 2026 년 10 월 28 일 11:01:58 KST 에 시작하였으며, 10 월 29 일 14:28:41 KST 에 최종 분석을 마쳤다. 중단 시간을 포함한 전체 경과시간은 27 시간 26 분 43 초였다. 총 160 개 업무 흐름에서 480 개 단계 응답을 확보하였고, 최종 집계 시점에 미해결 상태로 남은 운영 실패, 실행 절차 위반 또는 복구 차단은 없었다. 수치 제약 충족 여부는 별도의 실험 결과로 평가하였으며, 전송·복구 과정과 요청별 비용의 상세 기록은 부록 A 에 제시하였다.

4.2 원출력, 외부 정규화와 최종 적용 비중

모델이 처음 제시한 투자비중을 원비중 u, 실험 시작 전의 보유비중을 h, 검사와 후속 처리를 거쳐 최종적으로 적용한 비중을 w로 구분하였다. 모델의 원문과 원비중은 수정하지 않고 보존하였으며, 먼저 원출력이 비중 합계와 위험상한 등 정해진 제약조건을 충족하는지 검사하였다. 처음부터 모든 제약을 충족한 응답은 '원출력 유효'로 분류하였다. 여기서 유효하다는 것은 정해진 제약을 충족했다는 의미이며, 투자 판단의 품질까지 높다는 의미는 아니다.

외부 정규화는 모델 밖의 코드가 비중 합계를 맞추는 절차다. 이 절차는 열두 개 산업의 비중이 모두 유한한 비음수이고, 합계가 양수인 경우에만 적용하였다. 각 산업의 원비중을 전체 합계로 나누어 합계가 1 이 되도록 하였다. 예를 들어 산업이 두 개뿐인 경우를 가정하면, 원비중이 0.6 과 0.6 일 때 각각을 합계 1.2 로 나누어 0.5 와 0.5 로 조정하는 방식이다. 따라서 산업 간 상대적인 비율은 유지하면서 전체 합계만 조정할 수 있도록 하였다.

정규화 계산 후 컴퓨터의 소수점 연산으로 발생한 미세한 합계 오차는 가장 큰 비중에만 반영하였다. 이후 원래의 위험상한과 나머지 제약조건을 다시 검사하였다. 원출력은 제약을 충족하지 못했으나 이러한 합계 조정과 재검사를 통과한 경우는 '정규화 구제'로 분류하였다. 정규화의 적용조건을 충족하지 못하거나 정규화 후에도 제약 위반이 남은 경우는 실패로 기록하고 기존 보유비중 h를 적용하였다. 음수를 0 으로 바꾸거나 부호를 뒤집어 제안을 구제하지는 않았다. 정규화 결과와 처리 내역은 원응답과 구분하여 저장하였다.

$$w = u / \Sigma_k u_k \quad (\textit{정규화 자격을 갖추고 원래 제약을 충족한 경우})$$

$$w = h \qquad (\textit{최종 제안이 처리 규칙을 통과하지 못한 경우})$$

최종 적용 비중 w는 모델의 제안뿐 아니라 외부 정규화와 실패 시 기존 보유를 유지하는 정책이 함께 반영된 결과다. 예를 들어 모델의 제안이 실패하더라도 펀드별 기존 보유비중이 서로 다르면 최종

결과에는 펀드 간 차이가 남을 수 있다. 따라서 최종 비중에서 관찰된 차이 전체를 모델이 만들어낸 차이로 해석하지 않았다.

분석에서는 실패 사례를 제외하지 않고 최종 적용 비중 전체에서 펀드 간 배분 차이인 전략적 이질성을 평가하였다. 이후 원출력 유효·정규화 구제·실패를 구분하여 결과의 형성 경로를 살펴보았다. 이러한 구분은 최종 결과가 어떤 처리 과정을 거쳤는지 설명하기 위한 것으로, 각 유형의 독립적인 인과효과를 뜻하지 않는다. 또한 유효한 제안이 기존 보유비중 h를 실제로 변경했는지도 확인하여, 제약 충족 여부와 재배분 여부를 구분하였다. 비중 검사의 허용오차와 두 배분을 동일하다고 판단하는 기준은 부록 B 에 제시하였다.

4.3 필요한 차이와 과잉수렴

펀드 간 배분 차이를 평가할 때에는 단순히 서로 다른 배분을 제시했는지보다, 각 펀드의 조건에 맞는 차이를 유지했는지가 중요하다. 이를 평가하기 위해 본 연구에서 설정한 정보, 목적함수 및 제약조건에 따라 계산한 기준배분 v를 비교 대상으로 사용하였다. 여기서 '필요한 차이'는 이러한 수리적 기준배분에서 나타나는 펀드 간 차이를 뜻한다. 이는 설정한 모형 안의 평가 기준이며, 실제 투자 현장에서 반드시 필요한 차이를 직접 입증하는 것은 아니다.

펀드 간 배분 거리는 총변동거리(TV)로 계산하였다. TV 는 두 배분의 산업별 비중 차이에 절댓값을 취해 합한 뒤 절반으로 나눈 값이다. 예를 들어 두 산업에 대한 배분이 각각 60%·40%와 40%·60%라면 TV 는 20%p 다. 이는 한 배분을 다른 배분으로 바꾸기 위해 전체 자산의 20%를 산업 간에 옮겨야 한다는 의미로 이해할 수 있다. 펀드 i와 j의 최종 적용 비중을 w_i, w_j, 기준배분을 v_i, v_j라고 할 때, TV 와 과잉수렴 지표 G는 다음과 같이 정의한다.

$$D_{ij} = \tfrac{1}{2} \Sigma_k |w_{ik} - w_{jk}|, \quad D*_{ij} = \tfrac{1}{2} \Sigma_k |v_{ik} - v_{jk}|$$

$$G_{ij} = D*_{ij} - D_{ij}$$

G는 기준배분 사이의 거리에서 최종 적용 비중 사이의 거리를 뺀 값이다. 따라서 G가 양수이면 펀드들이 기준보다 가까워졌음을, 음수이면 기준보다 멀어졌음을 나타낸다. 예를 들어 기준거리가 30%p 이고 실제거리가 10%p 이면 G는 20%p 로, 기준에서 나타난 차이보다 펀드 간 차이가 줄어든 경우다.

$G = 0$은 두 거리의 크기가 같다는 뜻이며, 산업별 배분이나 차이의 방향까지 기준과 같다는 뜻은 아니다. 또한 G가 작아지는 것을 항상 개선으로 해석할 수는 없다. 양수에서 0 에 가까워지는 것은 과잉수렴의 감소를 나타내지만, 큰 음수가 되는 것은 기준보다 차이가 과도하게 벌어진 경우이기 때문이다. 이러한 문제는 다음 절의 거리 오차와 차이 패턴 지표를 함께 사용하여 평가하였다.

G와 거리·차이 패턴 오차 A·E는 동일한 상황·자료 제공 조건·반복에 속한 네 펀드의 여섯 비교쌍에서 계산하였다. 여섯 비교쌍은 같은 펀드를 공유하므로 각각을 독립 표본으로 취급하지 않았다. 본문의 거리 수치는 비중 차이를 쉽게 읽을 수 있도록 100 을 곱한 %p 단위로 보고하였다.

4.4 차이의 정합성과 기대수익 손실

평균 G 만으로는 서로 다른 방향의 오차가 상쇄될 수 있다. 이를 보완하기 위해 비교쌍별 거리 오차 A 와 차이 방향의 불일치 E 를 계산하였다. A 는 실제 거리와 기준 거리의 절대 차이이며, E 는 두 펀드 사이

산업별 비중 차이의 벡터가 기준의 벡터에서 벗어난 정도다. 거리가 같더라도 서로 다른 산업을 구분했다면 E 는 크게 나타날 수 있다.

$$A_{ij} = |D*_{ij} - D_{ij}|$$

$$E_{ij} = ½ \Sigma_k |(w_{ik} - w_{jk}) - (v_{ik} - v_{jk})|$$

$$R_i = \mu_i^T (v_i - w_i)$$

R 은 동일한 정보와 제약 아래 기준배분에 비해 포기한 월간 사후 기대수익이다. 본문에서는 1bp=0.01%p 로 환산한다. 이 값은 합성 전망을 사용하는 모형상 기회비용이며 실현 투자수익률과 구분된다. 해석을 돕기 위해 모든 펀드가 기존 h 를 그대로 유지했을 때의 같은 지표도 계산하였다. 이는 저장된 입력으로 산출한 비교 기준으로 별도 모델 실행을 추가하지 않는다.

G·A·E 와 품질 지표 R 은 상황 ID, 자료 제공 조건과 반복 번호로 연결한다. 먼저 여섯 비교쌍의 G·A·E 와 네 펀드의 R 을 각각 평균해 상황·조건별 결과를 만들고, 조건별 전체 결과는 열 상황의 평균을 동일한 비중으로 합산한다. 이번 수행의 반복은 한 차례이며, 단계 응답을 별도 표본으로 늘리지 않았다. 필요한 차이와 품질의 공동 개선은 같은 상황·조건의 지표들을 함께 비교하는 뜻이다. 이 집계만으로 개별 펀드쌍의 과잉수렴과 손실이 함께 발생한 빈도를 산출한 것은 아니며, 조건 평균의 관계를 모든 펀드와 비교쌍에 적용하지 않는다.

4.5 배분의 형성 경로와 수정 과정의 진단

실패는 음수 목표비중, 정규화 후 위험상한 위반 등 실제 발생 위치에 따라 구분하였다. 원비중이 h 또는 −h 와 같은지, 작성 단계에서 점검 단계로 가며 유효성과 적용 비중이 달라졌는지도 확인하였다. 계산도구는 설명의 표현과 실제 호출 기록을 구분해 집계하였다. 이 진단은 실패가 최종 적용 비중과 이질성 지표에 어떻게 연결됐는지를 설명한다.

수리 기준배분의 가까운 최적해 사이에서 발생할 수 있는 차이는 별도 수치 범위로 확인하였다. 이 범위는 최적화 기준의 수치적 모호성을 다루며 표본의 신뢰구간으로 사용하지 않는다. 최종 분석에 쓰인 입력과 응답의 해시, 정규화 결과와 상황별 지표는 저장된 기록을 바탕으로 재검산하였다.